

20170243 심재운

#1

#1-a.

$$\eta_{ij} = \begin{cases} 1, & \text{if } x_i \text{ and } x_j \text{ are same label pair.} \\ 0, & \text{otherwise.} \end{cases}$$

$$y_{il} = \begin{cases} 1, & \text{if } x_i \text{ and } x_l \text{ are same label pair} \\ 0, & \text{otherwise.} \end{cases}$$

이들은 indicator variable로 label이 같은지와 관련한 variable이다.

#1-b.

first term : positive pair의 거리함을 minimization하고 싶다.

$x_i$ 와  $x_j$ 가 같은 class라면 pull 한다.

second term : pair data에 관한 것과 triplet data에 관한 것이다. (same/different)

$x_l$ 을  $x_i$ 로 부터 push한다 (만약 다른 class라면)

negative pair을 멀리 보내고 싶은 것이다.

#1-c.

hinge function은 triplet 관계에 대해서 이용할 수 있다. 그래서

Negative pair의 거리가 정적으로 결정될 수 있다. 이는 positive pair와

Margin에 대해서 영향을 받고, 결국 large margin nearest

neighbors hinge function 사용한 것이다. 이는 결국 more flexible하다.

20170243 심재운

#2.

#2-a.

가정 ① Color constancy -  $I_t$ 과  $I_{t-1}$ 에서 점은 같다.

가정 ② small motion. - 점들이 그리 크게 떠가지 않는다.

#2-b. ① 번을 사용한다. Brightness constancy 가정을 사용하여 유도할 수 있다.

$$I(x, y, t-1) = I(x+u, y+v, t) \approx I(x, y, t) + u \cdot \nabla_x I(x, y, t) + v \cdot \nabla_y I(x, y, t)$$

$$u \cdot \nabla_x I(x, y, t) + v \cdot \nabla_y I(x, y, t) \approx I(x, y, t-1) - I(x, y, t) = -\nabla_t I(x, y, t)$$

$$\therefore [\nabla_x I(x, y, t) \quad \nabla_y I(x, y, t)] \begin{bmatrix} u \\ v \end{bmatrix} = -\nabla_t I(x, y, t)$$

#2-c.

$$\begin{bmatrix} \nabla_x I(x_1, y_1, t) & \nabla_y I(x_1, y_1, t) \\ \nabla_x I(x_2, y_2, t) & \nabla_y I(x_2, y_2, t) \\ \vdots & \vdots \\ \nabla_x I(x_9, y_9, t) & \nabla_y I(x_9, y_9, t) \end{bmatrix} \begin{bmatrix} u \\ v \end{bmatrix} = \begin{bmatrix} \nabla_t I(x_1, y_1, t) \\ \nabla_t I(x_2, y_2, t) \\ \vdots \\ \nabla_t I(x_9, y_9, t) \end{bmatrix} \Leftrightarrow A \begin{bmatrix} u \\ v \end{bmatrix} = b.$$

$A^T A \begin{bmatrix} u \\ v \end{bmatrix} = A^T b.$

#2-d.

①  $A^T A$ 는 invertible 해야 한다. ( $= A^T A$ 는 full-rank이다.  $\Rightarrow A^T A$ 의 eigenvalue는 non-zero이다.)

②  $\lambda_1 / \lambda_2$ 는 너무 크지 않아야 한다. ( $\lambda_1 > \lambda_2$  가정)  $\rightarrow$  두의 차이가 거의 없다.

③  $A^T A$ 의 eigen value는 작으면 안된다.

20170243 심재운

#3.

#3-a. probabilistic - particle filtering (generative)  
(resampling → state transition → observation)

deterministic - tracking by detection (discriminative)  
(online learning manner)

#3-b. 1<sup>st</sup> order Markov assumption

→ 현재 state인  $z_t$ 는 이전 state인  $z_{t-1}$ 에만 의존한다. 그리고 현재 observation  $z_t$ 는 현재 state인  $z_t$ 에만 의존한다.

#3-c

pros - 일관 모든 Video frame을 다 보고서 거기서 detection 했다가 한다. 그래서  
occlusion이나 이런한 문제를 잘 처리할 수 있다.

cons - object detection model이 전체 video frame을 필요하다.  $\rightarrow$  costly.  
offline 방식이다.

20170243 심재운

# 3-d. Soccer ball.  speed, direction. w/ illumination change. real time system.

- state space : 축구공의 location 은 time 틈에서 vector로 정의된다.

$$x_t = [x, y, s]^T \in \mathbb{R}^3$$

- appearance model : sample candidate들을 찾아 축구공과 비슷한 것을 선택한다.

선택된 Bounding box는 타겟으로 하는 축구공과 매우 일정하게 할 것이다.

- motion model : particle filtering 등과 같은 probabilistic tracking 방식을 사용하거나 축구공의 sample들을 random하게 sampling 하겠다.

이에 여러 가설들을 가지고 있고 계속해서 weight 따라 update가 가능하다.

20170243 심재운

#4.

$$\#4-a. \min \sum_{i=1}^n w_i (ax_i + b - y_i)^2 = \min \|w(x_a - y)\|^2.$$

$$\frac{d \|w(x_a - y)\|^2}{da} = 2(wx)^T w(a^T x - y) = 0.$$

$\therefore a = (x^T w^T w x)^{-1} x^T w^T y$

#4-b.


① Vertical distance는 rotation invariant이다.

② Vertical distance는 infinite로 가게 되는데 그러면 numerical unstable하다.  
(기울기가 심할시)


#4-c. ordinary least square는 vertical distance이지만, total linear least square는

per perpendicular distance를 사용한다.

$$\min \sum_{i=1}^n (ax_i + by_i + c)^2 = \min \|x_a\|^2.$$



vs.



#4-d.

우의 objective function을 그래도 optimization하면 trivial solution of  $a = [0, 0, 0]^T$ 가 존재한다. 이는 적절하지 않고, 우리가 원하는 결과도 아니다. 그래서 constraint가 필요하다.

$(kax + kb y + kc = 0 \Leftrightarrow x_a = 0 \text{을 풀어야 한다.})$

#4-e.

$\min \|x_a\|^2$ . Subject to  $\|a\|=1$  to avoid trivial solution.

$\rightarrow$  eigen decomposition 사용.  $\|x_a\|^2 = (x_a)^T (x_a) = a^T x^T x a = a^T (v^T D v) a = (v_1)^T D (v_1)$

$\rightarrow$  new objective function 사용:  $\min \|x_a\|^2 = \min k^T D k$  subject to  $\|k\|=1$ .

&  $D = \text{diagonal matrix with eigenvalue}$ ,  $k = V a$ .

$\rightarrow a = V^T k$  or  $k = [0, 0, \dots, 0, 1]^T$ .

$x^T x$ 에 eigen decomposition을 하면  $a^*$ 은 가장 작은 eigen value를 갖기하는 eigen vector이다.

20170243 심재운

#5.-a.

$$T = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} \rightarrow \text{location change}$$

$\text{dof} = 2$

$t_x : x\text{-축 이동}$   
 $t_y : y\text{-축 이동}$

$$E = \begin{bmatrix} \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix} & \begin{bmatrix} t_x \\ t_y \end{bmatrix} \\ \begin{bmatrix} 0 & 0 \end{bmatrix} & 1 \end{bmatrix} \rightarrow \begin{array}{l} \text{rotation,} \\ \text{translation.} \end{array}$$

$\text{dof} = 3$

$b = 2$

$$S = \begin{bmatrix} s\cos\theta & -s\sin\theta & t_x \\ s\sin\theta & s\cos\theta & t_y \\ 0 & 0 & 1 \end{bmatrix} \rightarrow \begin{array}{l} s: \text{scale} \\ \text{change} \end{array}$$

$\text{dof} = 4$

$s: \Delta \text{카별 감소}$

$$A = \begin{bmatrix} \begin{bmatrix} a_1 & a_2 \\ a_3 & a_4 \end{bmatrix} & \begin{bmatrix} t_x \\ t_y \end{bmatrix} \\ \begin{bmatrix} 0 & 0 \end{bmatrix} & 1 \end{bmatrix} \rightarrow \begin{array}{l} \text{non-singular} \\ \text{transform} \end{array}$$

$\text{dof} = 6$

$$H = \begin{bmatrix} h_1 & h_2 & h_3 \\ h_4 & h_5 & h_6 \\ h_7 & h_8 & h_9 \end{bmatrix} \rightarrow \text{homography.}$$

$\text{dof} = 8$

20170243 심재운

#5-b. Do  $F(m) = 1.$  & 2개로 6개의 world image point correspondence 찾기.

#5-c.

$$m^* = \underset{m}{\operatorname{argmin}} m^T A^T A m \quad \|m\| = 1.$$

$$m = [m_{11}, m_{12}, \dots, m_{34}]^T$$

$$A = \begin{bmatrix} x_1, y_1, z_1, 1 & 0 & 0 & 0 & 0 & -\bar{u}_1 x_1 & -\bar{u}_1 y_1 & -\bar{u}_1 z_1 & -\bar{u}_1 \\ 0 & 0 & 0 & 0 & x_1, y_1, z_1, 1 & -\bar{v}_1 x_1 & -\bar{v}_1 y_1 & -\bar{v}_1 z_1 & -\bar{v}_1 \\ \vdots & & & & & & & & \\ x_n, y_n, z_n, 1 & 0 & 0 & 0 & 0 & -\bar{u}_n x_n & -\bar{u}_n y_n & -\bar{u}_n z_n & -\bar{u}_n \\ 0 & 0 & 0 & 0 & x_n, y_n, z_n, 1 & -\bar{v}_n x_n & -\bar{v}_n y_n & -\bar{v}_n z_n & -\bar{v}_n \end{bmatrix}$$

#5-d.

$$m^* = \underset{m}{\operatorname{argmin}} m^T A^T A m \quad \text{subject to } \|m\| = 1.$$

$\rightarrow e_1^T \in A^T A e_1$  eigen vector 2t 째,  $\lambda_1^2 \in A^T A e_1$  eigen value 2t 째.

$\rightarrow$  unit vector  $x$  를 놓고 이를  $e_1$  를 linear combination으로 표현  
 $x = \mu_1 e_1 + \dots + \mu_{12} e_{12} \quad \& \sum_{i=1}^{12} \mu_i^2 = 1$

$$\rightarrow x^T A^T A x - e_1^T A^T A e_1 = (\mu_1 \lambda_1)^2 + \dots + (\mu_{12} \lambda_{12})^2 - \lambda_1^2 \geq 0.$$

$$\rightarrow x^T A^T A x - e_1^T A^T A e_1 \geq 0.$$

$$\rightarrow m^* = e_1$$